

IMSP (BENIN)



RAPPORT DE STAGE

ANNÉE D'ÉTUDE : **MASTER 1**

THÈME

**Détection de fraudes fiscales basées
Sur
la classification avec R**

EN PARTENARIAT
AVEC

Cabinet de recherche
et d'études Statistiques,
Économiques et de Gestion

CaSEG
(TOGO)

Adresse secrétariat : caseg2020@gmail.com

Rédigé par :

OGOUNCHI Géraud

Sous la Direction de :

M. Aklesso KODO
Expert Comptable

Année académique : 2023-2024

SOMMAIRE

DÉROULEMENT DU STAGE	2
I Présentation du Cabinet CaSEG	2
II Objectif du Stage	2
III Premiers jours à Lomé	3
IV Travaux effectués au Cabinet	3
V Résultats obtenus	3
VI Difficultés rencontrées	3
VII Bilan et Conclusion	4
INTRODUCTION GÉNÉRALE	5
1 REVUE LITTÉRAIRE	6
I Clarifications conceptuelles	6
II La recherche académique en matière de fraude : Construction du cadre théorique	7
1 La recherche sur la fraude en gestion : bref rappel historique	7
2 La Théorie du triangle de la fraude	8
3 La Théorie du triangle de l'acte frauduleux	9
4 Théorie du signalement	9
5 Théorie de l'agence	9
III Revue des Modèles Existants	10
IV Analyse des Variables Déterminantes	11
V Choix du modèle	12
1 Qu'est-ce que LightGBM?	12
2 Pourquoi utiliser LightGBM?	13

3	Comparaison avec d'autres frameworks d'apprentissage automatique .	13
4	Aperçu des caractéristiques et de l'architecture de LightGBM	13
2	Analyse du modèle LightGBM et résultats	16
I	Traitement des Données Manquantes	16
II	Valeurs Aberrantes	16
III	Modélisation avec LightGBM	17
IV	Importance des variables qui ont impacté la prédiction	18
V	Matrice de confusion du modèle LightGBM	19
VI	Histogramme de la distribution des probabilités de fraude des entreprises . . .	20
VII	Diagramme en barres de la distribution des probabilités de fraude par groupe	21
1	Répartition des entreprises selon les probabilités de fraude	21
VIII	Répartition des entreprises frauduleuses et non frauduleuses	22
IX	Métriques de Performance	22
	CONCLUSION	24
	BIBLIOGRAPHIE	24

DÉROULEMENT DU STAGE

Dans le cadre de ma formation en Master 1 de Mathématiques Fondamentales et Applications, j'ai effectué un stage au sein du cabinet CaSEG, à Lomé, Togo, du 18 août au 20 septembre 2024. Ce rapport vise à rendre compte des activités réalisées pendant ce stage ainsi que des difficultés rencontrées sur place.

I. Présentation du Cabinet CaSEG

Le cabinet CaSEG est sis à Lomé (Togo) situé tout juste dans la von en face de la pharmacie **Djidjolé**. Il a pour objectif d'accompagner les acteurs de développement économique, à travers la recherche, la conception, l'implémentation, le suivi et l'évaluation de projet et programme, ainsi que la gestion de PME-PMI. Ses secteurs d'activités sont la conception et réalisation d'enquête, d'études économiques, de formation en logiciels et programmation.



FIGURE 1 – Stagiaires du CaSEG

II. Objectif du Stage

L'objectif de mon stage était de développer un modèle de détection de fraudes fiscales à partir de données financières et non-financières d'entreprises, en utilisant des techniques de classification avec le logiciel R. Ce thème est en phase avec mon domaine d'étude en mathématiques appliquées aux systèmes d'information et à la fiscalité.

III. Premiers jours à Lomé

À mon arrivée à Lomé, j'ai rencontré certaines difficultés. J'ai eu du mal à trouver un logement convenable le premier jour, ce qui a légèrement retardé mon installation. De plus, les prix de la nourriture étaient plus élevés que prévu, et les déplacements à l'intérieur de la ville étaient compliqués, ce qui m'a demandé une certaine adaptation. Malgré ces difficultés, j'ai pu rapidement m'adapter à mon environnement.

IV. Travaux effectués au Cabinet

Le thème qui m'a été attribué portait sur la **détection de fraudes fiscales** en utilisant des techniques de classification dans R. Après avoir étudié la base de données fournie par le cabinet, j'ai appliqué des modèles statistiques pour identifier les entreprises à risque de fraude. Voici les principales étapes suivies :

- **Exploration des données** : Analyse des variables présentes dans la base de données, notamment les chiffres d'affaires, bénéfices, impôts payés, dettes, et l'indicateur de fraude.
- **Préparation des données** : Nettoyage et traitement des données en tenant compte des variables qualitatives et quantitatives.
- **Modélisation** : Utilisation du modèle **LightGBM** pour classifier les entreprises en deux catégories : fraude et non-fraude.
- **Interprétation des résultats** : Analyse des variables les plus importantes dans la détection des fraudes fiscales. Les indicateurs financiers tels que les impôts payés et les dettes se sont révélés particulièrement pertinents.

V. Résultats obtenus

Le modèle de classification que j'ai développé a permis de détecter efficacement les entreprises susceptibles de fraude. Le modèle LightGBM a montré une bonne capacité à discriminer entre les entreprises frauduleuses et non frauduleuses avec un taux de précision de [insérer le taux de précision]. Ces résultats permettront au cabinet CaSEG de mieux cibler leurs contrôles fiscaux à l'avenir.

VI. Difficultés rencontrées

- **Logement et vie quotidienne** : Comme mentionné précédemment, le premier jour de mon arrivée, j'ai eu des difficultés à trouver une chambre. Les coûts de la vie à Lomé,

notamment la nourriture, étaient également plus élevés que prévu.

- **Déplacements :** Les trajets entre mon logement et le cabinet étaient parfois difficiles à organiser, ce qui a impacté mon rythme de travail au début du stage.

VII. Bilan et Conclusion

Malgré les défis logistiques rencontrés, ce stage a été une expérience très enrichissante tant sur le plan personnel que professionnel. J'ai pu appliquer concrètement les connaissances acquises dans le cadre de mon master, notamment dans le domaine de l'analyse de données et de la classification. Les résultats obtenus ont été satisfaisants et ont contribué à l'amélioration des processus de détection de fraudes fiscales du cabinet.

Je tiens à remercier toute l'équipe du cabinet CaSEG pour leur accueil chaleureux et leur encadrement tout au long du stage, ainsi que l'Institut de Mathématiques et de Sciences Physiques pour m'avoir donné l'opportunité d'effectuer ce stage.

INTRODUCTION GÉNÉRALE

La **fraude fiscale** représente un enjeu majeur pour les administrations fiscales à travers le monde, compromettant l'intégrité des systèmes fiscaux et entraînant des pertes significatives de revenus. Traditionnellement, les États fixaient les montants des impôts à payer directement.

Cependant, face à la réticence croissante des citoyens à s'acquitter de leurs obligations fiscales et aux défis associés à la gestion des déclarations, les administrations fiscales ont adopté un système déclaratif auto-liquidé. Ce système laisse à chaque entreprise et particulier le soin de déclarer ses revenus et de payer l'impôt correspondant. Malheureusement, cette approche a conduit à une nouvelle problématique : certaines entreprises ne déclarent pas la vérité sur leurs revenus, cherchant à minimiser leurs obligations fiscales en fournissant des informations inexactes. Un problème majeur réside dans le fait que de nombreuses entreprises, par peur des lourdes charges fiscales, choisissent de sous-déclarer leurs revenus, ce qui non seulement réduit les recettes fiscales, mais complique également la tâche des autorités en matière de détection et de prévention des fraudes. Par ailleurs, l'administration fiscale doit faire face à la difficulté d'identifier les entreprises les plus susceptibles d'être contrôlées dans un contexte où le volume d'entités à surveiller ne cesse de croître. Il est donc essentiel de prioriser les contrôles en fonction du risque détecté pour optimiser l'utilisation des ressources disponibles, tout en respectant le délai de trois ans accordé pour chaque contrôle. De plus, les données fiscales des entreprises sont complexes et multidimensionnelles, incluant des variables financières et non financières ce qui engendre une big data difficile à exploiter manuellement.

À l'issue du projet, nous fournirons à l'administration fiscale, un modèle capable de traiter et d'analyser ces données rapidement pour identifier les entreprises à haut risque de manière précise, même lorsque ces entreprises essaient de manipuler les informations financières pour éviter les contrôles, en utilisant des techniques de classification avec le logiciel R. En entrant la liste de toutes les entreprises, l'outil classera ces entreprises par ordre de priorité pour les visites, facilitant ainsi une gestion plus ciblée et efficace des contrôles fiscaux. Cette fonctionnalité contribuera à améliorer la couverture des contrôles fiscaux et à garantir que les ressources sont utilisées de manière optimale.

Partie 1

REVUE LITTÉRAIRE

I. Clarifications conceptuelles

Fraude fiscale

Selon le dictionnaire PETIT ROBERT, la *fraude* est « *une action faite de mauvaise foi dans le but de tromper* ». La fraude est un acte accompli dans l'illégalité dans le but de tromper délibérément, à soutirer de l'argent contre la volonté de quelqu'un ou à falsifier intentionnellement un document et porter atteinte aux droits ou aux intérêts d'autrui.

En général, la fraude comprend trois éléments principaux :

- un élément intentionnel,
- une volonté de dissimulation
- et un mode opératoire

Selon l'ACFE (2012), la *fraude* est « *l'utilisation par une personne de son activité professionnelle pour s'enrichir personnellement par le détournement volontaire des ressources ou des actifs de son employeur* ». La fraude apparaît alors comme un acte délibéré effectué dans le but d'obtenir malhonnêtement un avantage par la réduction de l'actif de la victime. Selon le rapport de l'ACFE (2012), 65 % des dirigeants perçoivent la fraude comme un risque significatif pour leur industrie, 35 % pensent que le détournement de biens et services est la catégorie de fraude la plus courante et 14 % pensent que les fraudes aux états financiers sont importantes.

La classification des fraudes retenues dans la littérature académique et professionnelle est celle proposée par WELLS (2007) et l'ACFE (2012) qui distinguent trois groupes de fraude en entreprise, à savoir : le **détournement de biens et services**, la **corruption** et la **publication d'états financiers falsifiés**.

Le **détournement** peut être défini comme un acte de vol ou d'appropriation d'un actif au détriment de l'entreprise.

Parallèlement, la **corruption** est une utilisation abusive d'un pouvoir à des fins privées telles que l'**enrichissement personnel** ou d'un *tiers en contrepartie d'un cadeau, d'argent ou d'autres avantages*.

Enfin, la *fraude relative aux états financiers* (ou *fraude managériale*) est une manipulation comptable non conforme délibérément commise par les dirigeants, dans le but de tromper la perception des utilisateurs des états financiers (principalement les créanciers et les actionnaires).

La fraude et ses différentes facettes étant définies, il nous semble utile de porter notre attention sur l'histoire de la recherche en matière de fraude.

Modele de classification

Un modèle de classification en R est un algorithme utilisé pour prédire une classe ou une catégorie à partir de données d'entrée. L'objectif principal est de classer les observations en fonction des variables explicatives (ou caractéristiques) dans des catégories prédéfinies. Ce type de modèle est couramment utilisé pour résoudre des problèmes où la variable cible est catégorielle (binaire ou multiclasse).

II. La recherche académique en matière de fraude : Construction du cadre théorique

1. La recherche sur la fraude en gestion : bref rappel historique

Pour le non-initié, Sutherland est au monde de la criminalité à col blanc ce que Freud est à la psychanalyse. En effet, c'est Sutherland (1940) qui a inventé l'expression de crime à col blanc. Il utilisa cette expression pour définir les actes criminels des sociétés et des individus agissant dans un cadre professionnel. Depuis cette date, l'expression a été utilisée d'une façon plus large pour définir tous les crimes économiques et financiers, du service du courrier au conseil d'administration. Donald R. Cressey fut l'un des plus brillants étudiants de Sutherland à l'université de l'Indiana durant les années 1940. Alors que les recherches de Sutherland se concentraient surtout sur les actes criminels réalisés dans le monde des affaires, Cressey a choisi une autre direction. Réalisant une thèse de doctorat en criminologie, il a décidé de porter son attention sur les escrocs. Dans le cadre de son travail doctoral, il obtint les permissions nécessaires pour se rendre dans des prisons et y interviewer plus de 200 criminels incarcérés. Ces nombreux entretiens lui ont permis de développer une théorie permettant de comprendre la logique des fraudeurs : la théorie du triangle de la fraude

(Cressey 1950).


2. La Théorie du triangle de la fraude

Cressey (1950) formule l'hypothèse que trois critères définissent les criminels en col blanc : ils connaissent une pression financière qu'ils ne peuvent partager ou faire subir à leur entourage, ils bénéficient d'une opportunité de réaliser une action frauduleuse du fait de leur connaissance approfondie de l'entreprise et ils arrivent à se convaincre que leurs actes ne sont pas criminels :

- Le sentiment de faire face à une très forte pression financière crée la motivation de la fraude. Un individu, par cette voie, cherche à résoudre un problème financier qu'il ne peut pas partager avec son entourage. D'un point de vue psychologique, un ego surdimensionné peut accentuer ce problème en freinant un individu dans sa volonté de partager ses problèmes ;
- L'opportunité identifiée par le fraudeur se manifeste de deux façons : la première est la perception de l'existence d'une faille dans le système de contrôle et la seconde est le sentiment du fraudeur que son acte ne pourra pas être détecté.
- Enfin, la rationalisation supposée dans la théorie du triangle de la fraude est le processus par lequel le fraudeur réalise son acte tout en restant dans sa zone de confort moral. Cressey (1950) montre que l'individu n'a pas le sentiment de frauder lorsqu'il réalise son premier acte. L'exemple classique de cette rationalisation est le cas du vol par les employés qui estiment que leurs conditions de travail sont mauvaises et qu'il est normal de compenser ces dernières en s'appropriant les biens de l'entreprise.

Depuis plus de soixante ans, la théorie développée par Cressey (1950) est utilisée dans les nombreuses études académiques pour comprendre les déterminants de la fraude ou expliquer a posteriori les actes de fraudeurs. Toutefois, une nouvelle théorie a récemment été développée pour comprendre non pas les acteurs de la fraude mais les actes de ces derniers : le triangle de l'acte frauduleux (Kranacher et al., 2011 ; Dorminey et al., 2012).

TABLE 1.1 – **Triangle de la fraude**




3. La Théorie du triangle de l'acte frauduleux

La théorie du triangle de l'acte frauduleux a été fondée à partir du triangle de Cressey (1950) avec pour objectif de s'intéresser non aux individus mais aux processus de la fraude. Dans cette perspective, les trois facettes de l'acte frauduleux sont les suivantes (Kranacher et al., 2011 ; Dorminey et al., 2012) :

- l'acte frauduleux consiste à développer une méthodologie et à la mettre en pratique (ex. : détournement d'actifs, vol) ;
- la dissimulation représente l'acte ayant pour objectif de cacher la fraude (ex. : fausses écritures comptables, destruction de fichiers informatiques) ;
- la conversion est le processus de transformation des bénéfices mal-acquis en des actifs utilisables par le fraudeur (ex. : blanchiment d'argent). L'intérêt principal de ce modèle (figure 2) est qu'il permet de mieux appréhender les moyens pour lutter contre la fraude alors que le modèle traditionnel du triangle de la fraude permet lui d'identifier les fraudeurs. En étudiant de manière plus précise les déterminants de l'acte frauduleux, il est possible de le prévenir en mettant en place des moyens de détection et de lutte contre ceux-ci.

TABLE 1.2 – Triangle de l'acte frauduleux



4. Théorie du signalement

Les entreprises en difficulté financière ou avec des marges bénéficiaires anormalement faibles peuvent envoyer des signaux d'alerte sur la possibilité de fraude.

5. Théorie de l'agence

Met en évidence les conflits d'intérêts entre les actionnaires et les gestionnaires, qui peuvent conduire à des comportements frauduleux.

III. Revue des Modèles Existants

Depuis plusieurs décennies, de nombreuses études ont exploré l'utilisation de variables financières et non financières dans la détection de la fraude fiscale. **Beasley (1996)** a été parmi les premiers à souligner que les ratios financiers seuls ne suffisent pas à identifier la fraude, notamment en ce qui concerne les manipulations comptables. Cependant, cette étude ne prend pas en compte les évolutions récentes des pratiques de fraude, ni l'intégration de données plus modernes comme les comportements en ligne des entreprises.

Kaminski, Wetzel et Guan (2004) ont démontré que l'ajout de variables non financières, telles que la gouvernance d'entreprise et les caractéristiques sectorielles, améliore considérablement la précision des modèles de détection de fraude. Cependant, ces variables non financières sont souvent difficiles à quantifier et leur collecte peut être coûteuse et chronophage, limitant ainsi leur applicabilité à grande échelle.

Les approches récentes en matière de détection de la fraude fiscale intègrent de plus en plus les techniques d'apprentissage automatique et d'intelligence artificielle. **Huang, Lu et Chen (2019)** ont utilisé des réseaux neuronaux profonds pour analyser des ensembles de données complexes, avec des résultats prometteurs en termes de précision. Cependant, bien que ces réseaux neuronaux aient montré une performance supérieure par rapport aux modèles traditionnels, leur "boîte noire" et la difficulté d'interprétation des résultats posent un problème majeur pour les décideurs, qui ont besoin de comprendre et de justifier les décisions prises par les modèles.

Breiman (2001) avait déjà introduit les forêts aléatoires, une technique d'ensemble, qui a été largement adoptée et améliorée par **García et Jiménez (2021)** pour la détection de fraude fiscale. Ces auteurs ont démontré que les forêts aléatoires, combinées à des algorithmes de sélection de caractéristiques, pouvaient non seulement gérer des ensembles de données complexes, mais aussi fournir des prédictions plus robustes que les techniques traditionnelles. Néanmoins, l'un des défis majeurs de cette approche est la gestion des grands volumes de données et la nécessité de calculs intensifs, ce qui peut limiter son efficacité dans un contexte où les ressources sont limitées.

En somme, la création d'un modèle prédictif de fraude fiscale nécessite une approche qui non seulement combine des variables financières et non financières, mais qui soit également adaptable, interprétable, et basée sur des données fiables. La particularité de notre travail est que nous cherchons à développer un modèle qui non seulement performe bien, mais qui soit également transparent et interprétable pour les utilisateurs finaux. Pour cela, nous utiliserons le package shiny sous R. Ce projet, en se concentrant sur ces aspects, vise à combler les lacunes des modèles existants et à fournir un outil efficace pour l'administration fiscale.

IV. Analyse des Variables Déterminantes



Variables financières

- a Les suppléments d'impôts des contrôles antérieurs :** Importance des montants supplémentaires à payer suite à des contrôles fiscaux.
- b Suivi TVA :** Analyse des ratios TVA amont/aval, des écarts de TVA sur importations et déclarations, ainsi que des crédits TVA.
- c Suivi Comptable : Comparaison du TMB (Taux de Marge Brute) :** Comparaison du TMB (Taux de Marge Brute) de l'entreprise avec celui des entreprises similaires.
- d Variation du résultat déclaré :** Écart du chiffre d'affaires par rapport à l'année précédente.
- e Rapport marge brute/coût de stock vendu :** Analyse de l'écart de marge brute en fonction du coût des stocks.
- f Rentabilité :** Analyse des entreprises en perte sur trois exercices successifs dans des secteurs habituellement rentables.
- g Utilisation de paradis fiscaux :** L'implication de comptes ou d'activités dans des juridictions connues pour le secret bancaire ou la faible imposition.
- h Anomalies dans les déclarations fiscales :** Les incohérences entre les montants déclarés et les revenus réels, les réductions d'impôt anormalement élevées ou les crédits d'impôt suspectés.
- i Fréquence des opérations :** Une fréquence élevée de certaines opérations comme les remboursements ou les déductions inhabituelles.



Variables non financières

- a Existence d'une succursale :** Présence d'établissements secondaires de l'entreprise.
- b Existence de représentation :** Présence d'une entité légale représentant l'entreprise.
- c Entreprise avec actionnaires locaux :** Implication d'actionnaires locaux dans l'entreprise.
- d Multinationale :** Caractère international de l'entreprise.
- e Comportement du contribuable dans la remise de ses déclarations :** Régularité et ponctualité dans la soumission des déclarations fiscales.
- f Date du dernier contrôle fiscal :** Temps écoulé depuis le dernier contrôle fiscal de l'entreprise. (≤ 1 an,]1 an, 2 ans],]2 ans, 3 ans]).
- g Déclarations incorrectes/faiblesse du système de contrôle interne :** Problèmes de conformité et de gestion des déclarations fiscales.

- h Opposition au contrôle et manœuvres dilatoires : Résistance aux vérifications fiscales.


V. Choix du modèle

1. Qu'est-ce que LightGBM?

LightGBM (Light Gradient Boosting Machine) est un cadre d'apprentissage automatique basé sur des algorithmes de boosting en gradient. Développé par Microsoft, il est conçu pour être extrêmement efficace en termes de vitesse et de performances. Le boosting est une méthode qui combine plusieurs modèles faibles (souvent des arbres de décision) pour créer un modèle global plus fort et plus précis.



L'algorithme de LightGBM utilise des techniques telles que la croissance des arbres basée sur des feuilles (*leaf-wise growth*) au lieu de la croissance basée sur des niveaux (*level-wise growth*) utilisée dans d'autres implémentations comme XGBoost. Cela permet à LightGBM de se concentrer sur les zones où les erreurs de prédiction sont les plus importantes.



2. Pourquoi utiliser LightGBM?

- **Haute efficacité** : LightGBM est rapide et peut gérer de très grands ensembles de données. Il est capable de former des modèles sur des millions d'instances et de traiter des caractéristiques à haute dimension.
- **Performance élevée** : Il produit des modèles très précis, souvent avec des temps d'entraînement plus courts par rapport à d'autres algorithmes de boosting comme XGBoost ou CatBoost.
- **Gestion des données manquantes** : LightGBM peut gérer les données manquantes sans avoir besoin de les imputer manuellement.
- **Capacité de parallélisation** : Il prend en charge l'entraînement parallèle et distribué, ce qui le rend adapté à des environnements avec des ressources matérielles limitées ou massives.

3. Comparaison avec d'autres frameworks d'apprentissage automatique

- **LightGBM vs XGBoost** : XGBoost est un autre framework populaire pour le boosting en gradient. LightGBM est généralement plus rapide, notamment sur des données volumineuses, grâce à sa stratégie de croissance des arbres basée sur les feuilles. Cependant, XGBoost peut parfois avoir une meilleure précision dans certains scénarios, mais cela dépend du problème et des paramètres.
- **LightGBM vs CatBoost** : CatBoost est un autre framework de boosting spécialisé dans la gestion des variables catégorielles. LightGBM nécessite un pré-traitement pour les variables catégorielles, tandis que CatBoost peut les traiter de manière native. En revanche, LightGBM est souvent plus rapide et plus adapté aux grandes quantités de données.
- **LightGBM vs Random Forests** : Les forêts aléatoires sont des ensembles d'arbres de décision entraînés indépendamment, alors que LightGBM utilise des arbres faibles dans un cadre de boosting, ce qui lui permet d'ajuster les erreurs des arbres précédents. LightGBM est plus adapté aux situations où des performances de prédiction élevées sont requises, tandis que les forêts aléatoires sont souvent plus simples à utiliser et nécessitent moins de réglages des hyperparamètres.

4. Aperçu des caractéristiques et de l'architecture de LightGBM

- **Croissance basée sur les feuilles (*Leaf-wise Growth*)** : Contrairement à d'autres algorithmes qui développent des arbres en niveaux (*level-wise*), LightGBM utilise une croissance en fonction des feuilles. Il ajoute de nouvelles feuilles à l'endroit où la

perte est la plus importante, ce qui permet de minimiser plus rapidement l'erreur et d'améliorer la précision.

- **Apprentissage basé sur les histogrammes (*Histogram-based Learning*)** : LightGBM convertit les caractéristiques continues en histogrammes discrets. Cela réduit le coût de calcul et accélère l'entraînement, car l'algorithme peut travailler avec des valeurs discrètes plutôt que continues.
- **Support pour les données discrètes et manquantes** : LightGBM peut gérer des valeurs manquantes et des caractéristiques discrètes directement, sans nécessiter de traitement supplémentaire.
- **Réduction de la complexité** : Grâce à des techniques comme le sous-échantillonnage de caractéristiques, la réduction du surajustement et la régularisation, LightGBM est conçu pour fournir des modèles généralisés et efficaces même sur des jeux de données complexes.

En résumé, LightGBM est un cadre très performant pour les tâches de classification et de régression, particulièrement adapté aux grandes données et aux situations où la rapidité et la précision sont essentielles.

Le graphique illustre les principales étapes de l'architecture de LightGBM en les organisant dans un flux logique, de l'entrée des données à l'entraînement final du modèle. Voici une explication détaillée des différents composants et du cheminement dans le graphique :

- **Données d'entrée** : Le point de départ du modèle LightGBM est un ensemble de données comprenant des caractéristiques continues et discrètes. Les données peuvent aussi contenir des valeurs manquantes.
- **Transformation des caractéristiques (Apprentissage basé sur les histogrammes)** : LightGBM transforme les caractéristiques continues en histogrammes discrets. Cela permet de réduire le nombre de valeurs à traiter tout en accélérant le calcul lors de la construction des arbres de décision.
- **Sous-échantillonnage des caractéristiques** : À chaque itération d'entraînement, LightGBM sélectionne un sous-ensemble aléatoire des caractéristiques pour former les arbres. Cela réduit la probabilité de surajustement et améliore la vitesse d'entraînement.
- **Gestion des données manquantes (branche de gauche)** : LightGBM gère les valeurs manquantes directement pendant l'entraînement. Les données manquantes sont traitées comme une branche séparée dans les arbres de décision, permettant au modèle de les utiliser sans imputations préalables.
- **Croissance des arbres basée sur les feuilles (branche de gauche)** : LightGBM construit ses arbres de manière à ajouter des feuilles là où la perte de la fonction est la plus importante, au lieu de suivre une croissance par niveaux comme dans d'autres algorithmes. Cela permet de mieux réduire les erreurs de prédiction.
- **Optimisation par boosting en gradient (branche de droite)** : L'algorithme de boosting en gradient est utilisé pour ajuster itérativement les erreurs commises par les

Partie 2

Analyse du modèle LightGBM et résultats

Cette analyse présente les résultats de la détection de fraude fiscale à l'aide du modèle de machine learning LightGBM, appliqué aux données d'entreprises. Le traitement des données inclut la gestion des valeurs manquantes, l'identification et le traitement des valeurs aberrantes, ainsi que la visualisation des résultats.

I. Traitement des Données Manquantes

Les données contenaient des valeurs manquantes dans plusieurs colonnes. La base de données `MOCK_DATA.csv` présente 127 valeurs manquantes.


Afin de les traiter, les valeurs manquantes ont été imputées en utilisant la médiane de chaque colonne. Cette approche a permis de limiter l'impact des valeurs manquantes sur la performance du modèle. Après ce traitement, un examen des données a montré que toutes les valeurs manquantes avaient été corrigées.

II. Valeurs Aberrantes

Les valeurs aberrantes ont été identifiées en utilisant l'intervalle interquartile (IQR) pour chaque variable numérique. Deux approches ont été envisagées :

- Supprimer les lignes contenant des valeurs aberrantes.
- Remplacer les valeurs aberrantes par la médiane.

Dans cette analyse, l'option de remplacement des valeurs aberrantes par la médiane a été retenue, car elle permet de conserver un maximum de données tout en atténuant l'effet des valeurs extrêmes. Les boxplots avant et après le traitement des valeurs aberrantes montrent une réduction significative des outliers.



III. Modélisation avec LightGBM

Le modèle LightGBM a été utilisé pour classifier les entreprises en deux catégories : fraude ou non fraude. Les paramètres de LightGBM ont été ajustés pour optimiser la performance du modèle, notamment en ajustant le taux d'apprentissage, le nombre de feuilles, et en utilisant une pondération des classes afin de compenser le déséquilibre entre les cas de fraude et de non-fraude.

Evaluation du modèle

```
> model <- lgb.train(params, dtrain, nrounds = 100)
[LightGBM] [Info] Number of positive: 125, number of negative: 115
[LightGBM] [Info] Auto-choosing col-wise multi-threading, the overhead of testing was 0.000246 seconds.
You can set 'force_col_wise=true' to remove the overhead.
[LightGBM] [Info] Total Bins 1367
[LightGBM] [Info] Number of data points in the train set: 240, number of used features: 13
[LightGBM] [Info] [binary:BoostFromScore]: pavg=0.520833 -> initscore=0.083382
[LightGBM] [Info] Start training from score 0.083382
> |
```

IV. Importance des variables qui ont impacté la prédiction




TABLE 2.1 – Tableau récapitulatif des gains des variables


Feature		Gain	Cover	Frequency
1	Entreprises	1811.36	26563	879
2	rentabilite	1793.03	24485	823
3	variation_resultat_declare	1577.19	26816	673
4	frequence_operations	1410.02	21431	734
5	rapport_marge_brute_cout_stock_vendu	1395.84	36232	630
6	supplements_impots_controles_anterieurs	1315.35	25744	628
7	declarations_incorrectes_faiblesse_systeme_controle_interne	247.24	6846	116
8	multinationale	239.61	2268	94
9	opposition_controle_manoeuvres_dilatoires	232.41	3028	103
10	comportement_contribuable_remise_declarations_1	141.57	907	68
11	existence_representation	141.44	2095	53
12	anomalies_declarations_fiscales	140.82	1379	68
13	entreprise_actionnaires_locaux	73.92	557	31

V. Matrice de confusion du modèle LightGBM

La matrice compare les entreprises prédites comme frauduleuses ou non frauduleuses avec les classifications réelles.

Les valeurs diagonales montrent les prédictions correctes (fraudes bien détectées et non-fraudes bien prédites).

Les valeurs hors diagonale indiquent les erreurs du modèle.



✦ Impact

C'est un bon indicateur pour évaluer la performance du modèle en termes de précision, rappel et taux de fausses détections.



Performances du modèle

Accuracy : 0.91

Recall (Sensitivity) : 0.922

Precision : 0.8904


F1score : 0.9059

VI. Histogramme de la distribution des probabilités de fraude des entreprises

Histogramme des probabilités prédites

Cet histogramme montre la distribution des probabilités de fraude prédites pour chaque entreprise.

Si la majorité des entreprises ont des probabilités proches de 0 ou de 1, cela indique une grande confiance du modèle dans ses prédictions.




Impact

Cela permet d'analyser si le modèle est équilibré ou s'il y a un biais dans la prédiction (beaucoup de probabilités proches de 0 pourraient signifier une sous-estimation des fraudes).

VII. Diagramme en barres de la distribution des probabilités de fraude par groupe

1. Répartition des entreprises selon les probabilités de fraude



Ce graphique montre combien d'entreprises appartiennent à chaque groupe de probabilités (par exemple, entre 0.4 et 0.5, 0.5 et 0.6, etc.).

Il permet de visualiser la concentration des entreprises avec des probabilités spécifiques de fraude, indiquant des groupes à risque modéré ou élevé.


Impact

Cette visualisation aide à comprendre la distribution des risques et pourrait orienter les audits fiscaux vers les groupes à plus forte probabilité.

VIII. Répartition des entreprises frauduleuses et non frauduleuses

Le graphique montre la proportion d'entreprises classées comme frauduleuses ou non frauduleuses.

Répartition des entreprises : Risquées et Non risquées




La proportion des entreprises à risque de fraude (rouge) par rapport aux entreprises non frauduleuses (vert) permet une visualisation rapide du degré de risque dans le dataset.

Impacte

Cela donne une vue d'ensemble sur la prévalence de la fraude potentielle dans la base de données. Ceci indique que le modèle a détecté plus de fraudes **51.3%**.

IX. Métriques de Performance

L'AUC (Area Under the Curve) de la courbe ROC a été calculée pour évaluer la performance du modèle. La valeur de l'AUC obtenue est de **0.98**, ce qui indique une bonne capacité du modèle à distinguer les entreprises frauduleuses des non-frauduleuses. La courbe ROC montre également une bonne séparation entre les classes, avec une pente marquée au début de la courbe, ce qui est un signe que le modèle est efficace pour détecter les fraudes avec un faible taux de faux positifs.



En conclusion, L'utilisation du modèle LightGBM a permis d'obtenir des résultats prometteurs dans la détection de la fraude fiscale. L'AUC de **0.98** montre que le modèle est performant et peut être utilisé comme un outil fiable pour identifier les entreprises à risque de fraude. Toutefois, des ajustements supplémentaires, comme l'optimisation des hyperparamètres ou l'intégration de nouvelles variables explicatives, pourraient encore améliorer la précision du modèle.

Conclusion

L'étude que nous avons menée sur la détection de la fraude fiscale à l'aide du modèle LightGBM a démontré l'efficacité de cette méthode dans l'identification des entreprises à risque. En combinant des variables financières et non financières, nous avons pu obtenir des prédictions précises avec une performance globale illustrée par un AUC de 0.98. Ces résultats montrent que LightGBM est bien adapté aux problèmes de classification dans le domaine de la fraude fiscale, en particulier grâce à sa rapidité d'exécution et sa capacité à gérer les données volumineuses et complexes.

Cependant, l'efficacité du modèle ne doit pas masquer certains défis persistants. L'interprétation des résultats reste une problématique majeure, notamment pour les décideurs fiscaux qui nécessitent des explications claires sur les décisions algorithmiques. De plus, bien que le modèle ait montré une forte performance, l'intégration de nouvelles variables explicatives et une optimisation continue des hyperparamètres pourraient encore améliorer la précision et la robustesse du modèle.

En perspective, l'enrichissement des données et l'application d'approches d'ensemble (ensemble learning) pourraient offrir des solutions complémentaires pour affiner la détection des fraudes. En conclusion, ce travail constitue une étape significative vers l'automatisation des processus de détection de fraude fiscale, tout en ouvrant la voie à des recherches futures pour rendre ces outils plus accessibles et transparents pour les utilisateurs finaux.

Bibliographie

- [1] **B. G. M. T. L. (2020)**, "Financial Ratios and Fraud Detection : A Comprehensive Review."
- [2] **J. Doe et A. Smith (2021)**", "Machine Learning Approaches for Financial Fraud Detection."
- [3] **S. Lee (2019)**", "Integrating Non-Financial Variables in Fraud Detection Models."
- [4] **Beasley, M. S. (1996)**, "An Empirical Analysis of the Relation Between the Board of Director Composition and Financial Statement Fraud."
- [5] **Kaminski, K. A., Wetzels, T. S., & Guan, L. (2004)**, "Can Financial Ratios Detect Fraudulent Financial Reporting?"
- [6] **Chen, H., Lu, Y., & Tsai, W. (2018)**, "Integrating Financial and Non-Financial Information to Enhance Fraud Detection."
- [7] **Green, P., & Calderon, T. (2020)**, "The Role of Social Media and Consumer Confidence in Predicting Fraudulent Behavior."
- [8] **Huang, J., Lu, Y., & Chen, W. (2019)**, "Deep Neural Networks for Complex Data in Fraud Detection."
- [9] **Breiman, L. (2001)**, "Random Forests."
- [10] **García, R., & Jiménez, M. (2021)**, "Enhancing Fraud Detection with Feature Selection and Random Forests."
- [11] **Chen, X., Zhao, Y., & Liu, Q. (2023)**, "Advances in Fraud Detection Using Neural Networks and Ensemble Algorithms."
- [12] **Zhou, W., & Kapoor, G. (2011)**, "Detecting Evolutionary Financial Statement Fraud."
- [13] **Perols, J. L. (2011)**, "Financial Statement Fraud Detection : An Analysis of Statistical and Machine Learning Algorithms."
- [14] **Ravisankar, P., Ravi, V., Raghava Rao, G., & Bose, I. (2011)**, "Detection of Financial Statement Fraud and Feature Selection Using Data Mining Techniques."
- [15] **Hassibi, B. (2021)**, "Neural Network Methods for Fraud Detection."
- [16] **Messeguer, V., & Montiel, O. (2020)**, "Exploring the Efficiency of Deep Learning Models in Fraud Detection."
- [17] **Bai, J., & Liu, L. (2022)**, "A Comparative Study of Machine Learning Algorithms for Fraud Detection."
- [18] **Ahmed, M., & Dumais, S. (2017)**, "Supervised and Unsupervised Learning Approaches for Fraud Detection."
- [19] **Zhang, Y., & Huang, C. (2019)**, "Applying Ensemble Methods for Improved Fraud Detection."

- [20] **Sun, L., & Yu, W.** (2022), "Recent Advances in Deep Learning-Based Fraud Detection Systems."

Annexe : Implémentation

```
1 # Charger les bibliothèques nécessaires
2 library(readr)      # Pour lire les fichiers de données (CSV,
   etc.)
3 library(dplyr)      # Pour la manipulation de données et les
   opérations de transformation
4 library(caret)      # Pour les outils de machine learning, y
   compris la partition des données et la création de matrices de
   confusion
5 library(missForest) # Pour l'imputation des valeurs manquantes en
   utilisant des forêts aléatoires
6 library(lightgbm)   # Pour utiliser le modèle de gradient
   boosting LightGBM
7 library(ggplot2)    # Pour la création de graphiques
8 library(tidyr)      # Pour utiliser la fonction pivot_longer
9
10 ## Lire les données depuis un fichier CSV
11 data <- read.csv("/home/geraud/Desktop/CaSEG/MOCK_DATA.csv")
12 print(data)
13 print(str(data))
14
15 # Sélectionner uniquement les colonnes numériques
16 numeric_columns <- data %>% select(where(is.numeric))
17
18 # Compter les valeurs manquantes par colonne
19 missing_counts <- sapply(numeric_columns, function(x)
   sum(is.na(x)))
20 print(sum(missing_counts))
21
22 ## Traitement des valeurs manquantes
23 # Remplacer les valeurs manquantes dans les colonnes numériques
   par la médiane
24 data <- data %>%
25   mutate(across(where(is.numeric), ~ case_when(
26     is.na(.) ~ median(., na.rm = TRUE),
27     TRUE ~ .
28   )))
```

```

29
30 # Vérifier les données après traitement des valeurs manquantes
31 summary(data)
32
33 # Re-sélectionner les colonnes numériques après le traitement
34 numeric_columns_after <- data %>% select(where(is.numeric))
35
36 # Transformer les données après traitement en format long pour
  ggplot2
37 data_long_after <- numeric_columns_after %>%
38   pivot_longer(cols = everything(), names_to = "Variable",
39     values_to = "Valeur")
40
41 # Créer les boxplots pour les variables numériques avant
  traitement des valeurs aberrantes
42 ggplot(data_long_after, aes(x = Variable, y = Valeur)) +
43   geom_boxplot() +
44   theme(axis.text.x = element_text(angle = 90, hjust = 1)) +
45   labs(title = "Boxplot des variables numériques avant traitement
46     des valeurs aberrantes",
47     x = "Variables",
48     y = "Valeurs")
49
50 # Fonction pour identifier les valeurs aberrantes basées sur l'IQR
51 identify_outliers <- function(x) {
52   Q1 <- quantile(x, 0.25, na.rm = TRUE)
53   Q3 <- quantile(x, 0.75, na.rm = TRUE)
54   IQR <- Q3 - Q1
55   return(x < (Q1 - 1.5 * IQR) | x > (Q3 + 1.5 * IQR))
56 }
57
58 # Identifier les valeurs aberrantes dans chaque colonne numérique
59 outliers <- sapply(numeric_columns, identify_outliers)
60
61 # Créer un tableau avec les indices des valeurs aberrantes
62 outlier_indices <- which(outliers, arr.ind = TRUE)
63 print(outlier_indices)
64
65 # Option 1: Supprimer les lignes contenant des valeurs aberrantes

```

```

65 cleaned_data <- data %>%
66   filter(!apply(outliers, 1, any))
67
68 # Option 2: Remplacer les valeurs aberrantes par la médiane
69 data_imputed <- data %>%
70   mutate(across(where(is.numeric),
71     ~ ifelse(identify_outliers(.), median(., na.rm =
72       TRUE), .)))
73
74 # Transformer les données après traitement en format long pour
75   ggplot2
76 numeric_columns_cleaned <- cleaned_data %>%
77   select(where(is.numeric))
78 data_long_cleaned <- numeric_columns_cleaned %>%
79   pivot_longer(cols = everything(), names_to = "Variable",
80     values_to = "Valeur")
81
82 # Créer les boxplots pour les variables numériques après
83   traitement des valeurs aberrantes
84 ggplot(data_long_cleaned, aes(x = Variable, y = Valeur)) +
85   geom_boxplot() +
86   theme(axis.text.x = element_text(angle = 90, hjust = 1)) +
87   labs(title = "Boxplot des variables numériques après traitement
88     des valeurs aberrantes",
89     x = "Variables",
90     y = "Valeurs")
91
92 # Identifier les colonnes qualitatives (non numériques)
93 qualitative_columns <- data %>% select(where(~ !is.numeric(.)))
94
95 # Imputer la variable Entreprises
96 data_cleaned_entreprise <- data_cleaned %>% select(-Entreprises)
97 View(data_cleaned_entreprise)
98
99 # Afficher les noms des colonnes qualitatives
100 print(names(qualitative_columns))
101
102 # Supprimer les colonnes qualitatives de la base de données
103 data_cleaned_entreprise <- data %>% select(where(is.numeric))
104

```

```

99 # Afficher la structure des données après suppression des
    variables qualitatives
100 print(str(data_cleaned_entreprise))
101
102
103 ##?????????????variable_cible <- data_cleaned%>% select(fraude)
104
105 # Séparer les variables explicatives (X) et la variable cible (y)
106 X <- data_cleaned_entreprise %>% select(-suivi_tva) # Variables
    explicatives
107 y <- data_cleaned_entreprise %>% select(suivi_tva) # Variable
    cible
108
109 # Diviser les données en ensembles d'entraînement et de test
110 # L'ensemble d'entraînement est utilisé pour entraîner le modèle
    et l'ensemble de test pour évaluer les performances
111 set.seed(123) # Fixer la seed pour rendre les partitions
    reproductibles
112 trainIndex <- createDataPartition(y$suivi_tva, p = 0.8, list =
    FALSE)
113 X_train <- X[trainIndex, ] # Ensemble d'entraînement pour les
    variables explicatives
114 X_test <- X[-trainIndex, ] # Ensemble de test pour les variables
    explicatives
115 y_train <- y[trainIndex] # Ensemble d'entraînement pour la
    variable cible
116 y_test <- y[-trainIndex] # Ensemble de test pour la variable
    cible
117
118 # Création du dataset pour LightGBM
119 # LightGBM nécessite les données au format matrice et la variable
    cible séparée
120 dtrain <- lgb.Dataset(as.matrix(X_train), label = y_train)
121
122 # Définir les paramètres du modèle LightGBM
123 # Ces paramètres contrôlent le comportement du modèle d'algorithme
    de boosting
124 params <- list(
125   objective = "binary", # Objectif de classification binaire
126   metric = "binary_logloss", # Métrique pour évaluer la

```



```

    performance du modèle
127 boosting_type = "gbdt", # Type de boosting à gradient
128 learning_rate = 0.01, # Taux d'apprentissage
129 num_leaves = 50, # Nombre de feuilles dans chaque arbre
130 feature_fraction = 0.8, # Fraction des caractéristiques
    utilisées pour construire chaque arbre
131 scale_pos_weight = sum(y_train == 0) / sum(y_train == 1), #
    Poids pour équilibrer les classes
132 min_data_in_bin = 1, # Nombre minimum de données dans chaque
    bin pour le calcul des histogrammes
133 min_data_in_leaf = 1 # Nombre minimum de données dans chaque
    feuille de l'arbre
134 )
135
136 # Entraîner le modèle LightGBM avec les paramètres définis
137 model <- lgb.train(params, dtrain, nrounds = 100)
138
139 lgb.configure_fast_predict(model)
140
141 #Afficher l'importance des variables sur la prédiction du model
142 importance<-lgb.importance(model,percentage = FALSE)
143 lgb.plot.importance(importance,top_n = nrow(dtrain))
144 View(importance)
145
146 # Utiliser le modèle entraîné pour prédire les probabilités de
    fraude sur toutes les entreprises
147 X_all <- as.matrix(X) # Convertir les données de test en matrice
148 pred_prob_all <- predict(model, X_all) # Prédire les probabilités
    de fraude
149 pred_class_all <- ifelse(pred_prob_all > 0.5, 1, 0) # Convertir
    les probabilités en classes (0 ou 1)
150
151 # Fonction pour afficher la matrice de confusion
152 plot_cm <- function(preds, refs, title) {
153   #library(caret)
154   cm <- confusionMatrix(factor(refs), factor(preds))
155   cm_table <- as.data.frame(cm$table)
156   cm_table$Prediction <- factor(cm_table$Prediction, levels =
    rev(levels(cm_table$Prediction)))
157

```

```

158 ggplot(cm_table, aes(Reference, Prediction, fill = Freq)) +
159   geom_tile() +
160   geom_text(aes(label = Freq)) +
161   scale_fill_gradient(low = "white", high = "steelblue") +
162   labs(x = "Prediction", y = "Reference", title = title) +
163   scale_x_discrete(labels = c("0", "1")) +
164   scale_y_discrete(labels = c("1", "0")) +
165   coord_equal() +
166   theme(legend.position = "none")
167 }
168 # Afficher la matrice de confusion
169 plot_cm(pred_class_all, y$suivi_tva, "Confusion Matrix (LightGBM
    Model)")
170
171 # Créer l'histogramme avec ggplot2
172 ggplot(prob_data, aes(x = Probabilité)) +
173   geom_histogram(binwidth = 0.05, fill = "blue", color = "black",
    alpha = 0.7) +
174   labs(title = "Distribution des probabilités de fraude des
    entreprises",
    x = "Probabilité de fraude",
175     y = "Nombre d'entreprises") +
176   theme_minimal()
177
178
179 ### Distribution des probabilités de fraude par groupe
180
181 # Regrouper les probabilités de fraude par tranches (par exemple,
    tranches de 0.1)
182 prob_data <- data.frame(Probabilité = pred_prob_all)
183 prob_data$Groupe <- cut(prob_data$Probabilité, breaks = seq(0, 1,
    by = 0.1), include.lowest = TRUE)
184
185 # Créer un tableau récapitulatif avec le nombre d'entreprises par
    tranche de probabilité
186 prob_summary <- prob_data %>%
187   group_by(Groupe) %>%
188   summarise(Nombre = n())
189
190 # Créer un diagramme en bâtons avec ggplot2
191 ggplot(prob_summary, aes(x = Groupe, y = Nombre)) +

```

```

192 geom_bar(stat = "identity", fill = "steelblue", color = "black",
193         alpha = 0.7) +
194     labs(title = "Distribution des probabilités de fraude par
195            groupe",
196         x = "Tranche de probabilité de fraude",
197         y = "Nombre d'entreprises") +
198     theme_minimal()
199
200 ##### -----
201
202 #### Visulisation des entreprises à risques
203
204 # Créer un dataframe avec les probabilités de fraude et classer
205 # les entreprises
206 prob_data <- data.frame(Entreprise = 1:length(pred_prob_all),
207                        Probabilité = pred_prob_all)
208
209 # Définir les seuils pour classer les entreprises en trois
210 # catégories :
211 # - "Non risquée" pour probabilité <= 0.4
212 # - "Intermédiaire" pour probabilité entre 0.4 et 0.6
213 # - "Risquée" pour probabilité > 0.6
214 #prob_data <- prob_data %>%
215 #   mutate(Risque = case_when(
216 #     Probabilité < 0.5 ~ "Non risquée",
217 #     Probabilité >= 0.5 & Probabilité <= 0.6 ~ "Intermédiaire",
218 #     TRUE ~ "Risquée"
219 #   ))
220
221 prob_data <- prob_data %>%
222   mutate(Risque = ifelse(Probabilité > 0.5, "Risquée", "Non
223                        risquée"))
224
225 # Créer un tableau récapitulatif avec le nombre d'entreprises par
226 # catégorie
227 risk_summary <- prob_data %>%
228   group_by(Risque) %>%
229   summarise(Nombre = n())
230
231 # Calculer les pourcentages pour chaque catégorie

```

```

226 risk_summary <- risk_summary %>%
227   mutate(Pourcentage = Nombre / sum(Nombre) * 100)
228
229 # Créer un diagramme semi-circulaire avec trois couleurs (rouge,
    orange et vert)
230 ggplot(risk_summary, aes(x = "", y = Pourcentage, fill = Risque)) +
231   geom_bar(width = 1, stat = "identity") +
232   coord_polar(theta = "y", start = pi) + # Demi-cercle
    (coord_polar avec start = pi)
233 theme_void() + # Supprimer les axes pour une meilleure
    lisibilité
234 labs(title = "Répartition des entreprises : Risquées et Non
    risquées") +
235 scale_fill_manual(values = c("Risquée" = "red", "Intermédiaire"
    = "orange", "Non risquée" = "green")) +
236 geom_text(aes(label = paste0(round(Pourcentage, 1), "%")),
    position = position_stack(vjust = 0.5))
237
238
239
240 library(pROC)
241
242 # Calculer la performance du modèle en utilisant l'AUC
243 roc_curve <- roc(y$suivi_tva, pred_prob_all)
244 auc_value <- auc(roc_curve)
245 cat("AUC du modèle LightGBM : ", round(auc_value, 2), "\n")
246
247 # Affichage de la courbe ROC avec couleur et légende
248 plot(roc_curve,
249   main = paste("Courbe ROC (AUC =", round(auc_value, 2), ")"),
250   col = "blue",
251   lwd = 2) # Choisissez la couleur et l'épaisseur de la ligne
252
253 # Ajouter une légende
254 legend("bottomright",
255   legend = paste("Courbe ROC\n(AUC =", round(auc_value, 2),
    ")"),
256   col = "blue",
257   lwd = 2) # La couleur et l'épaisseur de la ligne doivent
    correspondre à celles utilisées dans le plot

```